Projet 7

Implémentez un modèle de scoring

Khalil Henchi

Soutenance, le 09 février 2022

Encadrement : M. Amine Hadj-Youcef

Jury d'évaluation : M. Souhail Toumdi

Plan

- 1. Rappel de la problématique
- 2. Nettoyage de données
- 3. Analyse exploratoire de données
- 4. Modélisation : Machine Learning
- 5. Déploiement : API et Dashboard interactif
- 6. Conclusion et Perspectives

Présentation de la problématique

Contexte

Client

Prêt à dépenser : Crédits à la consommation

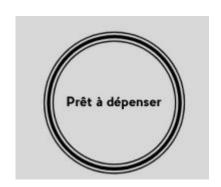
- Analyse de l'existant
 - Personnes avec peu ou pas d'historique de prêt

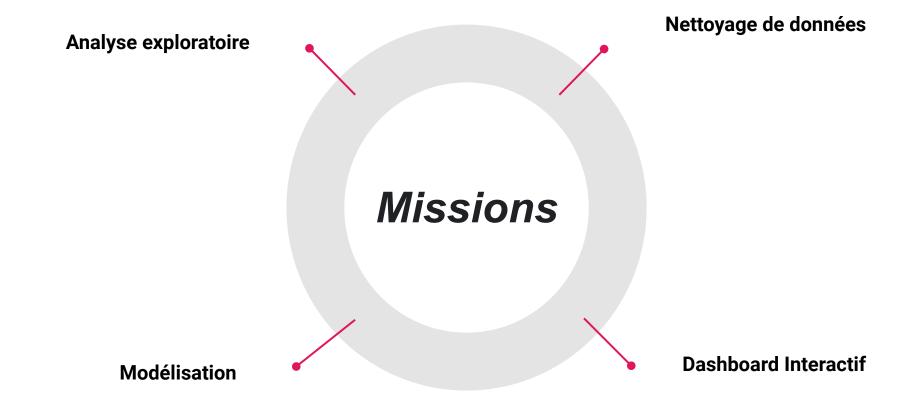
Problématique

- Attribution manuelle des crédits: peu Fiable et manque de transparence
- Est-il possible de réaliser une classification à l'aide des données disponible?

Objectifs

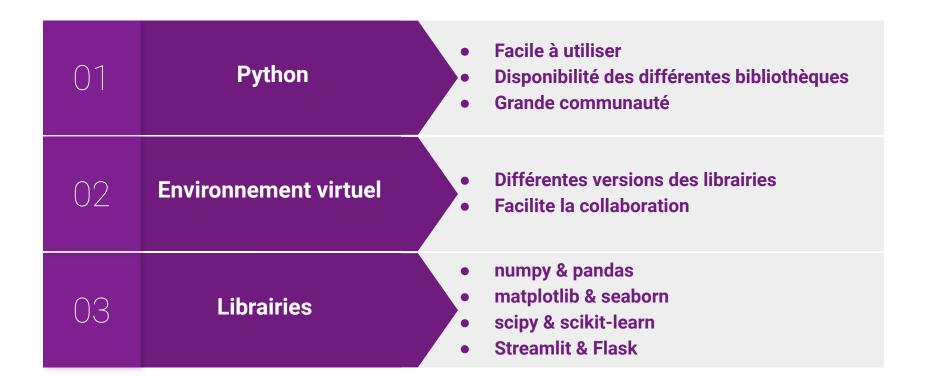
- Fiabiliser le processus : Développer modèle de scoring : probabilité défaut de paiement
- Réaliser un dashboard pour faciliter l'utilisation de l'outil développé





Travail à réaliser

- Préparer l'environnement du travail
- Nettoyer les données
- Valider la qualité des données
- Décrire et sélectionner les informations pertinentes
- Analyser le jeu
- Extraire des features
- Réduction de dimension
- Développer modèle de scoring
- Développer un dashboard interactif



Nettoyage et Analyse Exploratoire

01	Exploration de jeu de données et Identification des variables	 Quelles informations ? Quantités de données Quantités de données manquantes Informations pertinentes
02	Contrôle des variables	Vérifier la pertinence de chaque variable quant aux besoins métiers
03	Suppression des variables non pertinentes	Supprimer les variables non pertinentes en se basant sur le contrôle de l'étape 2
03	Suppression des doublons	Supprimer les observations dupliquées en se basant sur une variable unique
04	Nettoyage métier	Contrôler les variables et ses valeurs en se basant sur des connaissances métier
06	Traitement des valeurs aberrantes	 Supprimer Imputation Traiter séparément
07	Traitement des valeurs manquantes	 Imputation moyenne / mode / médiane Supprimer Prédiction

application {train|test}.csv Main tables - our train and test samples Présentation de donné Target (binary) Info about loan and loan applicant at application time - - SK ID CURR 9 fichiers SK ID CURR previous application.csv bureau.csv 307 511 clients Application data of client's Application data from previous previous loans in Home Credit loans that client got from other 122 Indicateurs Info about the previous loan institutions and that were parameters and client info at reported to Credit Bureau informations générales time of previous application SK_ID_CURR One row per client's loan in · One row per previous Credit Bureau informations sur application les prêts précédents -SK_ID_PREV

capacité ou non de payer crédit (solvabilité): Cible

> · Monthly balance of credits in Credit Bureau

SK ID BUREAU

bureau balance.csv

client's previous loans in Home Credit Behavioral data Behavioral data

POS CASH balance.csv

Monthly balance of

Past payment data for each installments of previous credits in Home Credit related to loans in our sample

instalments_payments.csv

SK ID PREV

Behavioral data

Monthly balance of client's previous credit card loans in Home Credit

credit card balance

Behavioral data

Autres opérations de nettoyage

- Kaggle kernels
- Feature engineering : pourcentage du montant des crédits sur la totalité des revenus, la durée totale du paiement des crédits, ...
- Gestion des données manquantes : suppression lignes et colonnes
- Standardisation, encodage des variables catégorielles

Analyse exploratoire

01	Exploration de jeu de données et Identification des variables	 Quelles informations? Quantités de données Quantités de données manquantes Informations pertinentes
02	Analyse univariée	 Travailler variable par variable statistiques classiques: moyenne, variance, médiane, etc. histogramme, boxplot
03	Analyse multivariée	 Analyse croisée Diagramme de dispersion Matrice de corrélation
04	Traitement des valeurs manquantes	 Imputation moyenne / mode / médiane Supprimer Prédiction
05	Traitement des valeurs aberrantes (outliers)	 Supprimer Imputation Traiter séparément
06	Transformation variable	LogarithmeRacine carrée / cubique
07	Création de variables	Création de nouveaux variablesCombiner

Analyses univariées

Première étape d'une analyse exploratoire

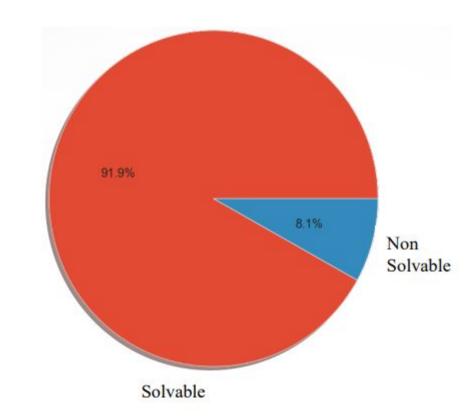
- travailler variable par variable
- numériquement et graphiquement

Variable numérique

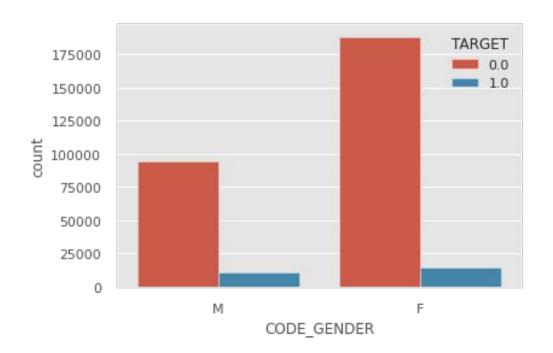
- à valeurs dans R
- statistiques classiques : moyenne, variance, médiane, etc.
- représentations associées :
 - Histogramme
 - Boxplot
 - Diagramme circulaire (Pie chart)

Déséquilibre de la Target

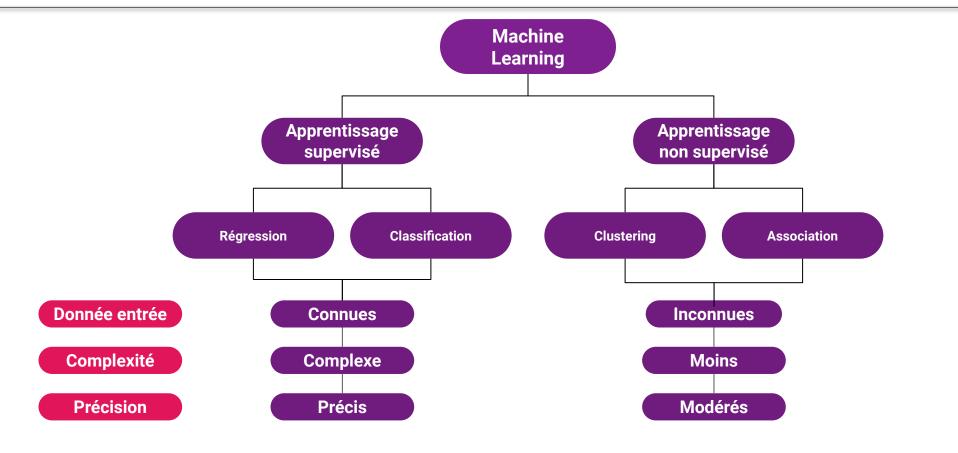
Fort déséquilibre entre les personnes solvables et les personnes non solvables.



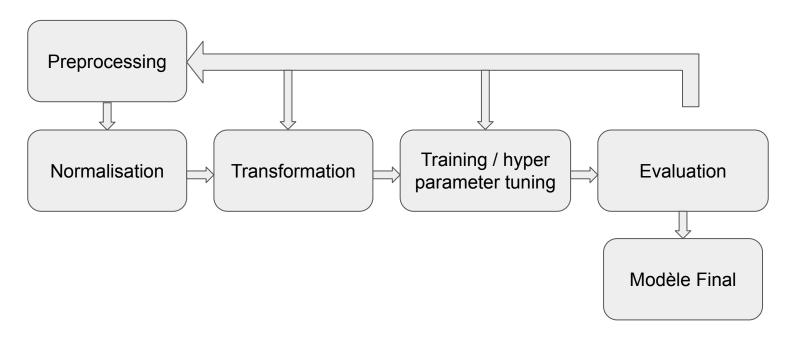
Genre masculin a tendance à être plus défaillants



Modélisation : entraînement de modèles



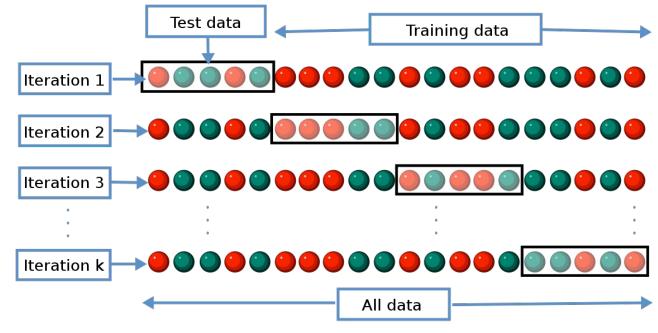
Data project Work Flow



Préparation des données

Division du jeu de données

- Train (80%):
 - Validation croisée
- Test (20%)

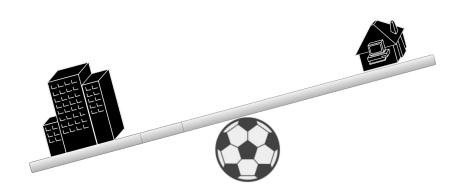


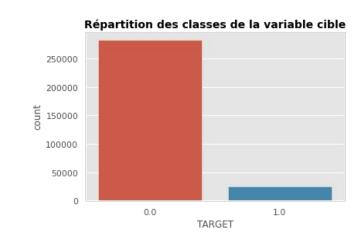
Déséquilibre de la cible

- → Impact performance
- Prédiction incorrecte

Solutions

- Class weights
- Over-sampling
- Under-sampling
- SMOTE





Fonction coût à optimiser

Classe 0 = Solvabilité

Classe 1 = Difficulté de paiement

TP : Accorder / Rembourser = gain

TN : Non accorder / Non rembourser = neutre

FN : Non accorder / Rembourser = perie

FP : Accorder / Non rembourser = perte

	Prédiction								
	Positive	Negative							
	0	1							
0	True positive (TP)	False negative (FN)							

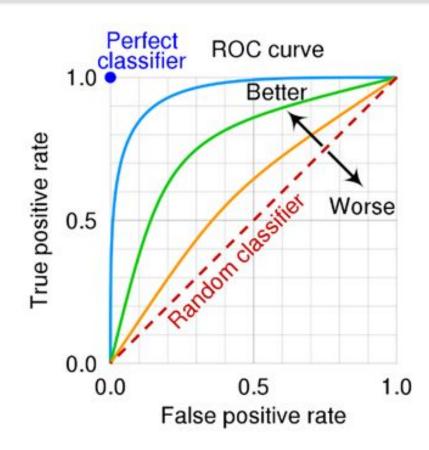
L				0	1
		Positive	0	True positive (TP)	False negative (FN)
	Réelle	Negative	1	False positive (FP)	True negative (TN)

Evaluation des modèles

AUC = Aire sous la courbe ROC :

→ capacité d'un classificateurà distinguer les classes

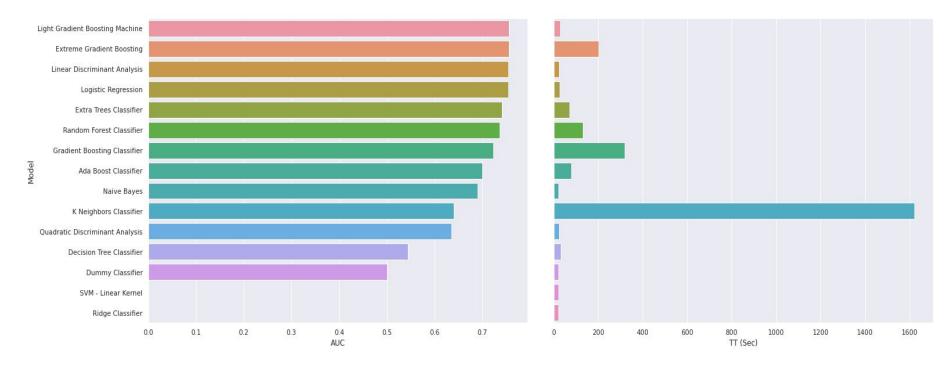
$$F_{\beta} = (1 + \beta^2) rac{Precision \ . \ Recall}{eta^2 \cdot Precision \ + \ Recall}$$



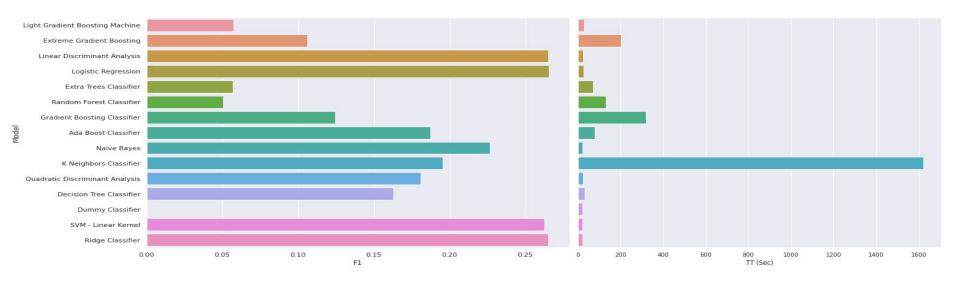
Choix des modèles

	Model	Accuracy	AUC	Recall	Prec.	F1	Kappa	MCC	F10Score	TT (Sec)
lightgbm	Light Gradient Boosting Machine	0.9181	0.7562	0.0306	0.4418	0.0573	0.0473	0.0992	0.0309	29.4550
xgboost	Extreme Gradient Boosting	0.9175	0.7560	0.0604	0.4426	0.1063	0.0885	0.1400	0.0610	203.0390
lda	Linear Discriminant Analysis	0.6893	0.7549	0.6900	0.1641	0.2651	0.1541	0.2184	0.6688	24.6900
Ir	Logistic Regression	0.6938	0.7544	0.6823	0.1650	0.2657	0.1552	0.2181	0.6617	25.8910
et	Extra Trees Classifier	0.9175	0.7411	0.0307	0.3988	0.0570	0.0459	0.0920	0.0310	69.9840
rf	Random Forest Classifier	0.9175	0.7361	0.0271	0.3869	0.0506	0.0403	0.0844	0.0273	130.2630
gbc	Gradient Boosting Classifier	0.9105	0.7222	0.0783	0.3028	0.1243	0.0941	0.1187	0.0788	319.6870
ada	Ada Boost Classifier	0.8850	0.6999	0.1631	0.2197	0.1871	0.1267	0.1284	0.1635	78.5190
nb	Naive Bayes	0.6545	0.6901	0.6225	0.1384	0.2264	0.1078	0.1587	0.6016	21.6530
knn	K Neighbors Classifier	0.5438	0.6401	0.6830	0.1141	0.1956	0.0655	0.1172	0.6509	1623.1170
qda	Quadratic Discriminant Analysis	0.8379	0.6354	0.2342	0.1590	0.1811	0.1044	0.1082	0.2324	23.7600
dt	Decision Tree Classifier	0.8381	0.5445	0.1939	0.1404	0.1629	0.0758	0.0770	0.1932	33.1900
dummy	Dummy Classifier	0.9188	0.5000	0.0000	0.0000	0.0000	0.0000	0.0000	0.0000	21.7910
svm	SVM - Linear Kernel	0.6855	0.0000	0.6884	0.1622	0.2625	0.1509	0.2149	0.6670	22.9040
ridge	Ridge Classifier	0.6893	0.0000	0.6901	0.1641	0.2651	0.1541	0.2185	0.6689	21.6560

Choix des modèles AUC

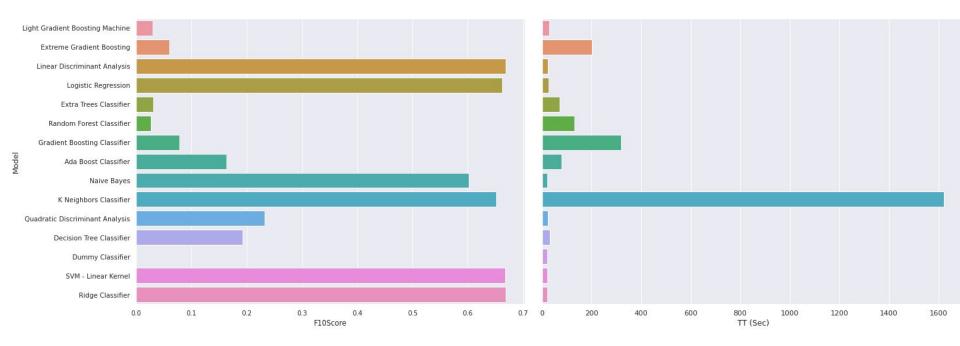


Choix des modèles F1 Score

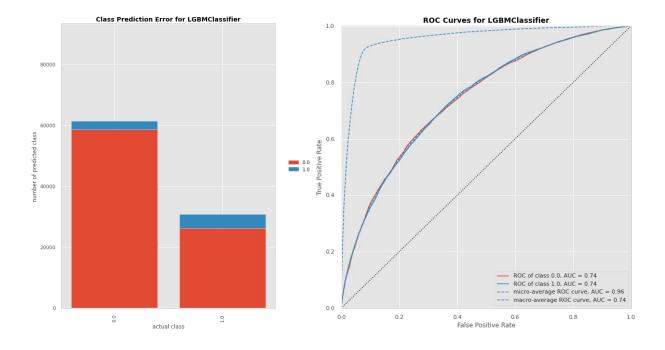


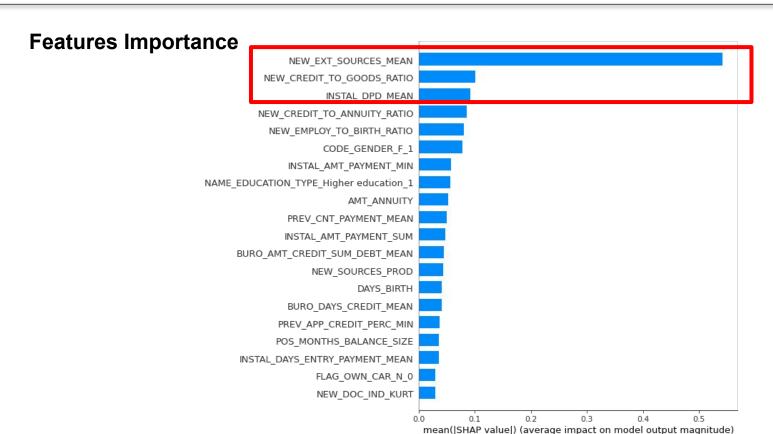


Choix des modèles F10 Score



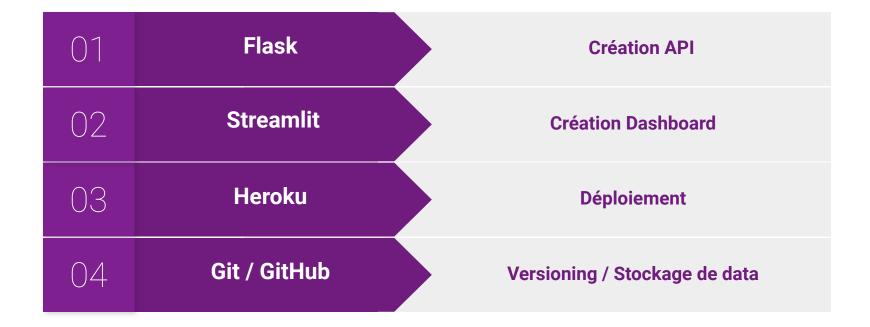
Modèle Choisi LGBM





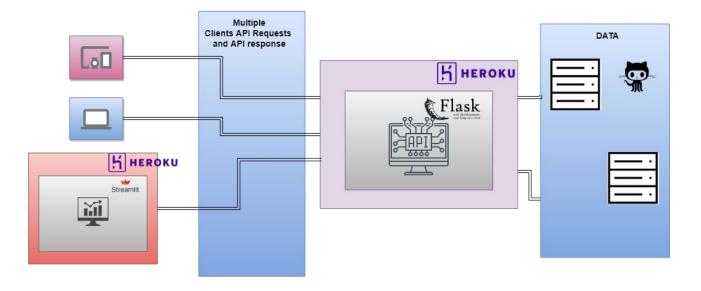
Dashboard Interactif : Architecture et Déploiement

Technologies



Architecture

Architecture: API and Dashboard

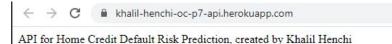


API





https://khalil-henchi-oc-p7-api.herokuapp.com/



 $\leftarrow \ \, \rightarrow \ \, \times \quad \, \text{ \^{a}} \ \, \text{ khalil-henchi-oc-p7-api.herokuapp.com/get_data/}$

{"X":"{\"SK ID CURR\": {\"0\":389086,\"1\":159006,\"2\":111210,\"3\":393584,\"4\":159312,\"5\":446262,\"6\":383229,\"7\":455506,\"8\":252474,\"9\":440644,\"10\":3 ,\"14\":182351,\"15\":379400,\"16\":174071,\"17\":429171,\"18\":437201,\"19\":204888,\"20\":158740,\"21\":370063,\"22\":181700,\"23\":43506 7\":371453,\"28\":126010,\"29\":273533,\"30\":243414,\"31\":174798,\"32\":453208,\"33\":328356,\"34\":167258,\"35\":275215,\"36\":424477,\" 348192,\"41\":397708,\"42\":208646,\"43\":447974,\"44\":126038,\"45\":410455,\"46\":289540,\"47\":331902,\"48\":174686,\"49\":202827,\"50\ 18,\"54\":347369,\"55\":246188,\"56\":327294,\"57\":204464,\"58\":368021,\"59\":378268,\"60\":450283,\"61\":282254,\"62\":337818,\"63\":308 "67\":319104,\"68\":194104,\"69\":150599,\"70\":425789,\"71\":150368,\"72\":196277,\"73\":418384,\"74\":257313,\"75\":392724,\"76\":448914, ":407002,\"81\":294447,\"82\":149762,\"83\":407792,\"84\":427030,\"85\":448493,\"86\":141713,\"87\":257674,\"88\":324692,\"89\":357908,\"96 9273,\"94\":245781,\"95\":124585,\"96\":128222,\"97\":174556,\"98\":107122,\"99\":388802,\"100\":102212,\"101\":207233,\"102\":279316,\"103 :272615,\"107\":438190,\"108\":189992,\"109\":273171,\"110\":273220,\"111\":356868,\"112\":420890,\"113\":309587,\"114\":196111,\"115\":282 6,\"119\":389047,\"120\":411392,\"121\":274427,\"122\":138394,\"123\":416837,\"124\":181306,\"125\":245374,\"126\":116699,\"127\":329657,\" 1\":445473,\"132\":171472,\"133\":355776,\"134\":369399,\"135\":403006,\"136\":226928,\"137\":227612,\"138\":166639,\"139\":395642,\"140\": 9943,\"144\":328803,\"145\":143639,\"146\":300236,\"147\":412438,\"148\":412779,\"149\":339669,\"150\":263272,\"151\":313004,\"152\":174096 "156\":102477,\"157\":316998,\"158\":190699,\"159\":123787,\"160\":287715,\"161\":214545,\"162\":108277,\"163\":384023,\"164\":157365,\"165 :375395,\"169\":404159,\"170\":266192,\"171\":326872,\"172\":402712,\"173\":236474,\"174\":420956,\"175\":421274,\"176\":405421,\"177\":146 3,\"181\":251438,\"182\":234001,\"183\":138503,\"184\":354551,\"185\":251873,\"186\":207460,\"187\":147914,\"188\":191900,\"189\":397340,\" 3\":213108,\"194\":408282,\"195\":202905,\"196\":176427,\"197\":331152,\"198\":305498,\"199\":311253,\"200\":383532,\"201\":198037,\"202\": 5319,\"206\":298971,\"207\":245352,\"208\":134820,\"209\":167920,\"210\":424379,\"211\":306953,\"212\":292371,\"213\":168182,\"214\":219657 "218\":422629,\"219\":445229,\"220\":449013,\"221\":243997,\"222\":330704,\"223\":189010,\"224\":400324,\"225\":327810,\"226\":252718,\"227 :162622,\"231\":409096,\"232\":241145,\"233\":191061,\"234\":327691,\"235\":401937,\"236\":356276,\"237\":437960,\"238\":225064,\"239\":318 2,\"243\":318845,\"244\":372153,\"245\":247520,\"246\":176823,\"247\":179469,\"248\":109412,\"249\":102779,\"250\":316343,\"251\":390868,\" 5\":215132,\"256\":366272,\"257\":296200,\"258\":414925,\"259\":325518,\"260\":314626,\"261\\":195639,\"262\":266626,\"263\\":363748,\"264\\": 4705,\"268\":315976,\"269\":376395,\"270\":108945,\"271\":139878,\"272\":351917,\"273\":149758,\"274\":128019,\"275\":144652,\"276\":27995 "280\":410850,\"281\":455181,\"282\":103860,\"283\":174737,\"284\":22160,\"285\":383798,\"286\":149941,\"287\":341139,\"288\":396633,\"289 :137823,\"293\":350584,\"294\":285443,\"295\":258765,\"296\":341694,\"297\":396967,\"298\":114565,\"299\":446879,\"300\":420426,\"301\":173 6,\"305\":143304,\"306\":151946,\"307\":236245,\"308\":254423,\"309\":308942,\"310\":221745,\"311\":221997,\"312\":132633,\"313\":406340,\" 7\":397763,\"318\":246265,\"319\":208015,\"320\":412591,\"321\":279529,\"322\":313046,\"323\":370175,\"324\":229123,\"325\":249757,\"326\": 9354,\"330\":375153,\"331\":265660,\"332\":329770,\"333\":126731,\"334\":188623,\"335\":420933,\"336\":342955,\"337\":342391,\"338\":36284 "342\":441167,\"343\":260214,\"344\":247949,\"345\":206613,\"346\":127270,\"347\":434397,\"348\":148612,\"349\":366863,\"350\":131363,\"351 Présentation Dashboard Interactif

Fonctionnalités

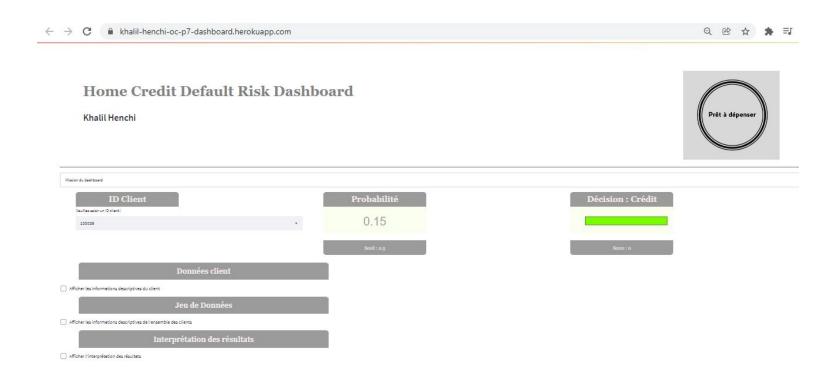
- Classification
 - □ Prédiction

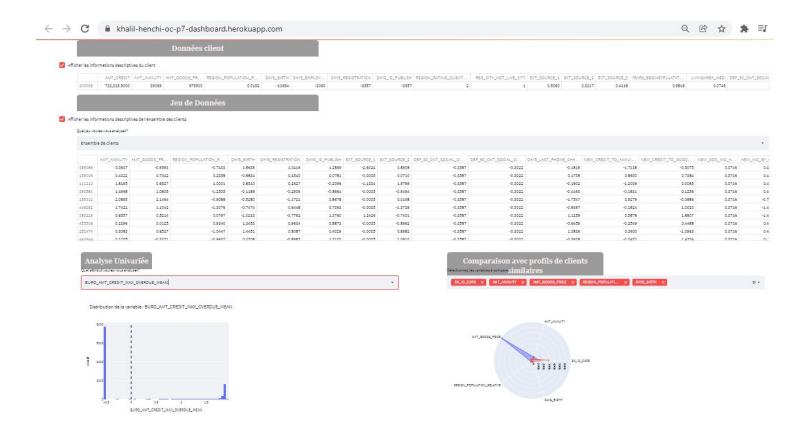
https://khalil-henchi-oc-p7-dashboard.herokuapp.com/

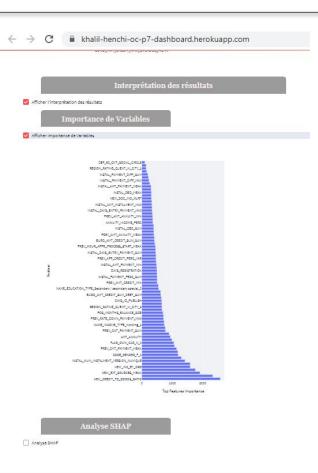
- - □ Visualisation
 - □ Comparaison de clients
- ☐ Interprétabilité
 - ☐ Globale: variables importantes
 - **□** Locale: SHAP

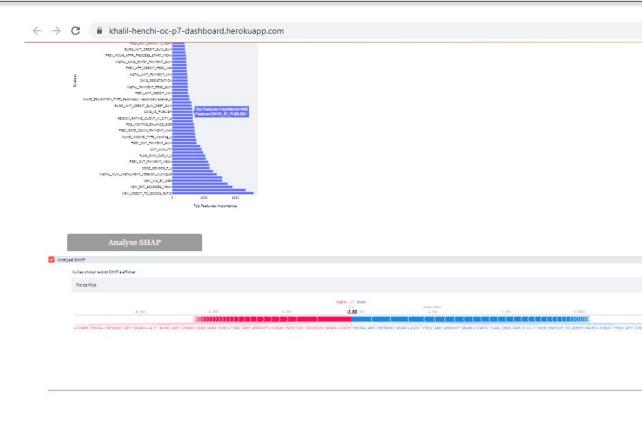












Conclusion

Livrables

- Jupyter Notebook détaillant le travail de nettoyage et modélisation
- Support de présentation

Compétences acquises

- Prétraiter des données pour obtenir un jeu de données exploitable.
- Mettre en œuvre des techniques de réduction de déséquilibre.
- Déployer un dashboard pour interagir avec le modèle.

Perspectives

- Améliorer le dashboard
- Présenter l'outil aux experts métiers
- Optimiser l'imputation des données

Merci pour votre Attention! A vos Questions

khalilhenchi@gmail.com



